Gestión distribuida de datos para aplicaciones de IoT

Claudio Omar Biale [1], Selva Nieves Ivaniszyn [1], Rubén Luis María Castaño [1], Ariel Lutenberg [2]

[1] Departamento de Informática, Facultad de Ciencias Exactas, Químicas y Naturales, Universidad Nacional de Misiones.

[2] CONICET-GICSAFe, Laboratorio de Sistemas Embebidos, Facultad de Ingeniería, Universidad de Buenos Aires

claudiobiale@fceqyn.unam.edu.ar, selvai@fceqyn.unam.edu.ar, rcastano@fceqyn.unam.edu.ar, alutenb@fi.uba.ar

RESUMEN

En un sistema tradicional de Internet de las Cosas (IoT), los datos recopilados por los nodos sensores y actuadores son enviados a la nube para su almacenamiento y análisis, mientras que los nodos reciben como respuesta comandos o instrucciones de control que producen cambios en sus actuadores. Este enfoque conduce a una alta latencia en la comunicación, un flujo de datos ascendente alto y mayores costos en los centros de datos en la nube. Adicionalmente, muchos sistemas de Internet de las Cosas experimentan problemas de conectividad que provocan la pérdida de datos si no existe un almacenamiento local coordinado. Este proyecto propone desarrollar un sistema distribuido que combina almacenamiento al borde de la red con servicios en la nube para mitigar estos inconvenientes. Este enfoque reduce latencias, optimiza el uso del ancho de banda y asegura la continuidad operativa en escenarios con conectividad limitada. Los resultados esperados incluyen un prototipo funcional que demuestre la viabilidad de esta arquitectura en aplicaciones reales.

Palabras clave: IoT, almacenamiento distribuido, borde-nube, conectividad, latencia.

CONTEXTO

Este trabajo de investigación se desarrolla en el marco del proyecto "16/Q2875-TI" de la Universidad Nacional de Misiones denominado “Gestión distribuida de datos para aplicaciones de IoT”.

1. INTRODUCCIÓN

La proliferación de dispositivos IoT plantea retos significativos en la gestión de datos debido a la alta dependencia de servicios en la nube. En regiones rurales con conectividad limitada, esta arquitectura no garantiza la operatividad continua, resultando en pérdidas de datos y latencias elevadas. La necesidad de sistemas de almacenamiento eficientes, con capacidades de consulta en tiempo real y procesamiento distribuido, ha impulsado el desarrollo de nuevas arquitecturas y enfoques en la gestión de datos en el borde de la red y la nube.

Diferentes estudios han explorado soluciones para manejar eficientemente los datos en entornos distribuidos. Feather es un sistema jerárquico y geo-distribuido que permite consultas eficientes con una garantía de frescura configurable, que balancea la latencia, el ancho de banda y la carga en los

nodos al borde [1]. FogStore introduce un modelo de almacenamiento clave-valor geo-distribuido, diseñado para optimizar la latencia y la tolerancia a fallos en entornos al borde, permite crear réplicas cercanas a los clientes para baja latencia y otras en ubicaciones remotas para tolerancia a fallas. Las consultas de clientes cercanos acceden a réplicas con consistencia fuerte, mientras que los clientes remotos reciben datos con consistencia eventual [2]. VergeDB plantea un enfoque basado en la compresión y análisis de datos en el borde que permite optimizar el uso de recursos computacionales disponibles, capacidad de almacenamiento y ancho de banda de red [3].

Además de estos enfoques, otros sistemas han explorado distintas optimizaciones en el almacenamiento y procesamiento de datos IoT. IoTDB propone un modelo de base de datos específicamente diseñado para manejar series temporales en entornos IoT, ofreciendo alta eficiencia en la ingesta y consulta de datos [4]. ModelarDB introduce una técnica de compresión mediante modelos matemáticos lo que permite representar series temporales con funciones que reducen drásticamente el tamaño de los datos sin perder precisión significativa. Implementa un mecanismo de transferencia continua de datos comprimidos desde el borde a la nube, esto asegura una administración eficiente del ancho de banda. Además, permite definir series temporales derivadas, que evitan el almacenamiento redundante de datos al recalcularlos dinámicamente [5]. TorqueDB es un motor distribuido para consultas sobre series temporales en dispositivos al borde y en la niebla, utiliza ElfStore para almacenamiento duradero en los nodos al borde e InfluxDB para consultas de los clientes en los nodos en la niebla [6].

Respawn es un sistema de almacenamiento distribuido multi-resolución para series temporales que particiona los datos entre la nube y el borde para optimizar consultas de baja latencia. Almacena datos en alta resolución en el borde y migra versiones agregadas y de menor resolución a la nube, para ello utiliza técnicas de predicción y caché adaptativa. Su arquitectura minimiza la transferencia innecesaria de datos y prioriza la migración de bloques estadísticamente relevantes, esto asegura un acceso eficiente sin depender de sincronización constante con la nube [7]. AnyLog, por su parte, es una base de datos descentralizada para gestión y consulta de datos IoT en arquitecturas al borde y en la nube. Utiliza una capa de coordinación descentralizada basada en un ledger compartido, que puede implementarse con blockchain u otros mecanismos. Los nodos se registran y sincronizan automáticamente, y gestionan datos localmente sin necesidad de redistribución constante. Este modelo elimina la dependencia de una base de datos centralizada y permite escalabilidad horizontal [8].

Otros enfoques han desarrollado estrategias específicas para el manejo de datos distribuidos. TS-Cabinet introduce una estrategia de almacenamiento jerárquico para bases de datos de series temporales en entornos de nube-borde-dispositivo final. Al utilizar modelos de temperatura de datos y predicción de carga de trabajo, este sistema optimiza la migración de datos entre diferentes niveles de almacenamiento para mejorar la eficiencia en las consultas y reducir la sobrecarga de almacenamiento [9]. LTSS, por otro lado, se centra en mejorar el rendimiento de la ingesta y la consulta de datos en entornos de alta carga al borde, ofreciendo una arquitectura optimizada para consultas en series temporales, superando en

rendimiento a soluciones como SQLite y PostgreSQL en múltiples escenarios de evaluación [10]. AIDA-DB propone un modelo de gestión de datos distribuidos para entornos al borde y en la nube que garantiza transacciones multi-sitio eficientes con baja latencia y alta escalabilidad. Implementa replicación total, ejecución optimista y, certificación y recuperación centralizada en la nube [11].

La investigación del trabajo se alinea con los desafíos actuales de sistemas de bases de datos distribuidas y almacenamiento eficiente de datos de sensores, explorando estrategias que optimicen la escalabilidad y la consulta de datos en entornos dinámicos y descentralizados. Se espera contribuir al desarrollo de soluciones más eficientes y adaptativas en la gestión de datos en IoT.

2. LÍNEAS DE INVESTIGACIÓN Y DESARROLLO

El trabajo de investigación aborda los siguientes ejes principales:

1. Almacenamiento distribuido: diseño de subsistemas de almacenamiento local en nodos al borde y almacenamiento en objetos en la nube.
2. Migración y almacenamiento de datos: estrategias para la compresión y transferencia de datos desde el borde a la nube de manera eficiente.
3. Consulta y escalabilidad: desarrollo de un servicio despachador escalable horizontalmente que coordine consultas globales que involucren a nodos al borde y a un sistema de almacenamiento en objetos en la nube. El sistema debe permitir realizar también consultas locales al borde de la red.

3. RESULTADOS OBTENIDOS/ESPERADOS

Este trabajo de investigación tiene como objetivo general el desarrollo de un sistema de captura, almacenamiento y consulta de datos distribuido transparente al usuario final donde los datos residen al borde de la red y en un servicio de almacenamiento en objetos en la nube. Las solicitudes al sistema pueden provenir de usuarios locales a un nodo al borde o de usuarios conectados a un servicio despachador ubicado en nodos en la nube.

En la actualidad, se encuentra en desarrollo el sistema de almacenamiento que consiste en una base de datos embebida al borde y un sistema de almacenamiento en objetos en la nube.

4. FORMACIÓN DE RECURSOS HUMANOS

El equipo de trabajo incluye a docentes e investigadores de las diferentes universidades. Como parte de este proyecto se encuentra en desarrollo una tesis de Maestría en Internet de las Cosas bajo la dirección del Dr. Ing. Ariel Lutenberg.

Adicionalmente se pretenden desarrollar actividades de extensión en el marco del ciclo de charlas denominado “AgriTech: soluciones IoT y tecnológicas para la agricultura” dictadas por integrantes del equipo de trabajo.

5. BIBLIOGRAFÍA

[1] Mortazavi, S. H., Salehe, M., Gabel, M., & de Lara, E. (2020). Feather: Hierarchical querying for the edge. In *2020 IEEE/ACM Symposium on Edge Computing (SEC)* (pp. 271-284). IEEE.

[2] Gupta, H., & Ramachandran, U. (2018). Fogstore: A geo-distributed key-value

store guaranteeing low latency for strongly consistent access. In *Proceedings of the 12th ACM International Conference on Distributed and Event-based Systems* (pp. 148-159).

[3] Paparrizos, J., Liu, C., Barbarioli, B., Hwang, J., Edian, I., Elmore, A. J., Franklin, M. J., & Krishnan, S. (2021). VergeDB: A database for IoT analytics on edge devices. In *Conference on Innovative Data Systems Research (CIDR 2021)*.

[4] Wang, C., Qiao, J., Huang, X., Song, S., Hou, H., Jiang, T., Rui, L., Wang, J., & Sun, J. (2020). Apache IoTDB: Time-series database for internet of things. *Proceedings of the VLDB Endowment*, *13*(12), 2901-2904.

[5] Jensen, S. K., Thomsen, C., & Pedersen, T. B. (2023). ModelarDB: Integrated model-based management of time series from edge to cloud. In *Transactions on Large-Scale Data-and Knowledge-Centered Systems LIII* (pp. 1-33). Springer Berlin Heidelberg.

[6] Garg, D., Shirolkar, P., Shukla, A., & Simmhan, Y. (2020). TorqueDB: Distributed querying of time-series data from edge-local storage. In *Euro-Par 2020: Parallel Processing: 26th International Conference on Parallel and Distributed Computing, Warsaw, Poland, August 24–28, 2020, Proceedings 26* (pp. 281-295). Springer International Publishing.

[7] Buevich, M., Wright, A., Sargent, R., & Rowe, A. (2013). Respawn: A distributed multi-resolution time-series datastore. In *2013 IEEE 34th Real-Time Systems Symposium* (pp. 288-297). IEEE.

[8] Nawab, F., & Shadmon, M. (2024). The tipping point of edge-cloud data management. In *Conference on Innovative Data Systems Research (CIDR 2024)*.

[9] Cui, S., Wang, H., Liu, X., Tian, Z., & Ding, X. (2023). TS-Cabinet: Hierarchical storage for cloud-edge-end time-series database. *arXiv preprint arXiv:2302.12976*.

[10] Waddington, D. G., & Lin, C. (2016). A fast lightweight time-series store for IoT data. *arXiv preprint arXiv:1605.01435*.

[11] Faria, N., Costa, D., Pereira, J., Vilaça, R., Ferreira, L., & Coelho, F. (2022). AIDA-DB: A data management architecture for the edge and cloud continuum. In *2022 IEEE 19th Annual Consumer Communications & Networking Conference (CCNC)* (pp. 1-6). IEEE.